

Creación de imágenes faciales que expresen emociones con el uso de redes GAN

Fabian Ordaz

Marzo 2025

1 Resumen

El presente artículo muestra el desempeño obtenido a través de una GAN (Red Generativa Antagónica) para generar imágenes que tengan las características de un rostro sorprendido, tomando como entrenamiento la base de datos de sorpresa de 3171 imágenes pertenecientes a FER-2013 de Kaggle.

2 Introducción

La inteligencia artificial en los últimos años ha tenido un crecimiento que nos acerca a la creación de nuevo contenido cuyo valor es la semejanza que tiene con el contenido creado por un ser humano.

En este contexto, la creación de imágenes con una Red Generativa Antagónica, a partir de ahora llamada GAN, es un modelo de inteligencia artificial para generar datos nuevos a partir de un conjunto de datos de entrenamiento. Usa dos redes neuronales que crecen a la par donde una ***el generador*** a partir de recibir un vector de ruido crea imágenes falsas pero que parezcan realistas, a la par que ***el discriminador*** se encarga de distinguir entre las creadas y reales (de entrenamiento) rechazando con más exactitud las pruebas que da su compañero cada vez más preciso. Con el tiempo, el generador se vuelve tan bueno que puede crear imágenes que parecen reales.

3 Objetivo

Aplicar una red generativa que permita crear imágenes que asemejen rostros que expresen emociones (sorpresa), siendo aplicable para otras emociones (miedo, felicidad, tristeza, enojo, disgusto y neutralidad)

4 Antecedentes

Las GAN tienen hoy en día amplio uso y aplicaciones, en creación de imágenes de flores [2] mejora de imágenes ya existentes [5] o manipulación de las mismas [1], además de que una de sus variantes ya ha sido comprobada con eficacia en materia de creación de rostros humanos [6].

Por otro lado, la eficacia de la base de datos de origen FER-2013 <https://www.kaggle.com/datasets/msmbare/fer2013?resource=download> ya tiene trabajos que demuestran la fidelidad de sus datos en modelos de clasificación convulacional. [4]

5 Método de trabajo

5.1 Red Generativa Antagónica

GAN (por sus siglas en inglés Generative Adversarial Network) es un tipo de modelo de inteligencia artificial diseñado para generar datos nuevos y realistas a partir de un conjunto de datos de entrenamiento.

El generador es responsable de crear nuevos datos que parezcan lo más posible al conjunto original de datos. El discriminador, por otro lado, tiene como objetivo distinguir entre los datos generados por el generador y los reales del conjunto original.

A medida que las dos redes se entrenan juntas, el generador aprende a producir datos que son cada vez más difíciles de distinguir de los datos reales, mientras que el discriminador aprende a ser más efectivo para distinguir entre los datos generados y los reales.

Con el tiempo, la salida del generador se vuelve cada vez más parecida a los datos reales y se logra una convergencia en la que el discriminador ya no puede distinguir con precisión los datos generados del conjunto original.

5.2 Partes de una GAN

Como mencionamos antes, la GAN consta de dos redes principales:

- Generador (Generator): Toma un vector de ruido aleatorio y genera imágenes falsas que intentan imitar las imágenes reales.
- Discriminador (Discriminator): Recibe una imagen (real o generada) y clasifica si es real o falsa.

Después, el generador toma un vector de ruido aleatorio (generalmente con una distribución normal). Se usan varias capas densas seguidas de activaciones para estabilizar el entrenamiento. El discriminador toma una imagen y clasifica si es real o falsa (de la base de datos o generada).

El entrenamiento de una GAN es un proceso iterativo en el que entrenamos el discriminador y el generador de forma alterna. La idea es que el discrimi-

nador aprenda a distinguir entre imágenes reales y generadas, mientras que el generador aprenda a crear imágenes que engañen al discriminador.

5.3 Modelo matemático GAN:

- Para t en n -Iteraciones:

1. Generar un lote de variables latentes $\mathbf{z} = \{z_1, z_2, \dots, z_m\}$ con $p(z) \sim \mathcal{N}(0, 1)$.
2. Leer un lote de imágenes reales $\mathbf{x} = \{x_1, x_2, \dots, x_m\}$.
3. Actualizar el discriminador mediante la solución aproximada de:

$$\min_{\theta_d} \sum_{i=1}^m \log D(x_i; \theta_d) + \sum_{i=1}^m \log [1 - D(G(z_i; \theta_g); \theta_d)].$$

4. Actualizar el generador mediante la solución aproximada de:

$$\max_{\theta_g} \sum_{i=1}^m \log [1 - D(G(z_i; \theta_g); \theta_d)].$$

- Fin del bucle.

5.4 Implementación de la GAN

- **Carga y normalización:** Se carga la base de datos; en esta ocasión, cargada desde Google Drive, se lee como imágenes en escalas de grises y re-dimensiona a 48 x 48 pixeles, todo esto por la naturaleza del origen de datos, se normaliza los valores de los pixeles entre $[0,1]$.
- **Conversión a Array Numpy:** Convertir la lista de imágenes a un array Numpy y agrega la dimensión del canal en escala de grises.
- **Construcción del modelo generador:** Se toman vectores aleatorios (ruido) y generan imágenes falsas en un modelo secuencial. Después, se crea el modelo en 3 tipos de capas, la capa inicial e intermedias donde se conecta el vector con la capa de neuronas, se evita que aplane la gradiente y estabiliza el entrenamiento, y la capa de salida donde se genera la imagen en escala de grises.
- **Construcción del modelo discriminador:** Mediante un modelo secuencial se va reduciendo la dimensionalidad mientras aprende las representaciones intermedias, al final, entrega un valor 1 para la real o 0 para una generada (falsa)
- **Congelamiento del discriminador:** En esta parte se cre el modelo que une ambas construcciones y se "congela" el discriminador, ya que de no ser así el generador jamás podrá engañarle.

- **Creación de la GAN:** Mientras se define el tamaño del ruido aleatorio, se construye y compila tanto el generador como el discriminador indicando que el generador se entrene y el discriminador solo evalúe.
- **Implementación de la función de entrenamiento:** Se selecciona un "batch" (grupo) de imágenes aleatorias, se generan imágenes falsas asignando a ambas una etiqueta 1 y las falsas con 0 entrenando con estas al discriminador.
Adicional al entrenar al generador, con etiquetas reales (1) y se pausa el entrenamiento del discriminador para que este pueda ser engañado.
- **Entrenamiento:** Se entrena el modelo indicando el número de pasos.

6 Resultados

Como podemos ver en las imágenes de resultado no se puede definir aún como un rostro humano, pero se empiezan a detectar oscuridad en los bordes y semejanzas a círculos en el centro de tonos más oscuros

Imagen Real



Imagen Generada




Imagen Real



Imagen Generada



Imagen Real



Imagen Generada





Imagen Real



Imagen Generada



7 Sugerencias para futuros seguimientos

Las GAN son redes "nuevas" del 2014 además de ser modelos complejos que pueden cambiar modificando algunas variables, por eso, para siguientes entrenamientos y mejoras en los resultados se proponen los siguientes puntos

7.1 Tamaño del Batch

El número de muestras procesadas en cada paso del entrenamiento, modificando el tiempo y estabilidad del modelo. Siendo este más grande haría que se estableciera más rápido con la precisión de las medias de pérdidas, alentando el tiempo de cómputo, en caso inverso, los resultados serían opuestos

7.2 Número de épocas

Este determina cuantas veces el modelo ve todo el conjunto de datos, por eso incrementar el número de épocas si el modelo aún no está generando imágenes de buena calidad después de un número razonable de pasos buscando no caer en el sobre ajuste.

7.3 Dimensiones del vector latente

Es la entrada del generador y determina la cantidad de variabilidad que puede generar el modelo. Valores grandes pueden darle la oportunidad al generador crear imágenes más variadas y detalladas, alentando el modelo en su entrenamiento.

7.4 Función de activación

Aunque LeakyReLU permite evitar el problema de neuronas muertas, no se debe descartar la posibilidad de usar ReLU [3]

7.5 Número de capas y neuronas

Las arquitecturas de las redes (el número de capas y neuronas) afectan la capacidad del modelo para aprender representaciones complejas.

7.6 Cambio de arquitectura

Si bien la investigación se hizo con base en el uso de una red GAN, la literatura nos indica que usar DCGAN tiene mejor rendimiento en la generación de imágenes realistas y detalladas cuando se trabaja con datos complejos como rostros.

El uso de capas convolucionales y convolucionales transpuestas captura mejor las relaciones espaciales en las imágenes, además con el uso de capas "Conv2DTranspose" se desaprenden las características aprendidas evitando el sobre ajuste [6]

8 Conclusiones

En la actualidad el dar más humanidad a los modelos de IA es esencial para que la naturalidad de los mismos genere confianza con los usuarios que interactúan con ellos, de esta manera se puede pretender romper esa barrera que se tiene.

De igual manera, el uso de estas herramientas tiene que ser con medida ya que los usos de la misma puede entrar en debate de regulaciones, uso, limitaciones y riesgos de aplicación.

References

- [1] Daiana Aranda, Julieta Gorla, Francisco Sandalinas, Mateo Suffern, and Pablo Negri. Manipulación de expresiones faciales vía espacio latente de red generativa antagónica (gan). In *Simposio Argentino de Imágenes y Visión (SAIV 2022)-JAIIO 51 (Modalidad virtual y presencial (UAI), octubre 2022)*, 2022.
- [2] Sergio Donís Ebri. Desarrollo de una red generativa antagónica para la generación de imágenes de flores falsas. 2022.
- [3] Andrea Navarro Moreno. Introducción a las redes neuronales aplicadas al aprendizaje supervisado.
- [4] Gabriel Ramos-Zacarias, Miguel Ángel Gil-Ríos, Alan López Martínez, María Dolores Juárez Ramírez, et al. Clasificación de emociones con reconocimiento facial utilizando aprendizaje profundo. *Emotion*, 12(2), 2025.
- [5] Sebastián Salazar-Colores, Hugo A Moreno, Ulises Moya, César J Ortiz-Echeverri, Luis A Tavares de la Paz, and Gerardo Flores. Eliminación de los efectos de humo en cirugía laparoscópica usando redes antagónicas generativas y el principio del canal oscuro. *Cirugía y cirujanos*, 90(1):74–83, 2022.

- [6] Israel Rivera Zárate, Miguel Hernández Bolaños, and Patricia Pérez Romero.
Redes adversarias para la generación de rostros sintéticos usando python.